본 문

(최소 10페이지 이상 작성)

딥러닝을 이용한 실시간 배경 제거

1 서론 4

2 관련 연구 5

2.1. Image Matting 5

2.2. 전이 학습 (Transfer learning) 5

3 연구 내용 5

3.1. MODNet 5

3.2. 자체 모델 구조 6

3.3. Consistency Constraint Loss 7

4 연구 결과 8

4.1. 학습 데이터 8

4.2. 데이터 증강 (Data augmentation) 8

4.3. 학습 방법 9

4.4. PPM-100에 대한 결과 9

4.4. 실제 적용 결과 10

5 결론 11

1 서론

Portrait matting은 주어진 이미지나 영상에서 사람을 추출하는 것으로, 사진 및 영상 편집과 같이 다양한 분야에서 사용된다. 최근 코로나 19로 인한 화상 회의 증가에 따른 화상 회의 서비스에서 제공하는 배경 제거 기술에 대한 수요의 증가로 Portrait matting의 중요도와 활용도가 더욱 높다. 이에 본 연구는 삼성SDS에서 제공하는 화상 회의 서비스인 Knox Meeting의 실시간 배경 제거 모델 개발을 위해 진행되었다. 모델 개발 시 고려해야 할 점은, (1) 실시간으로 사용할 수 있는 동시에 낮은 CPU 사용량, (2) GPU을 지원하지 않는 가상 데스크톱 인프라 (VDI) 환경이다. 자체 모델 개발에 앞서, 기반 모델을 찾기 위해 Mobile-Unet [1], DeeplabV3+ [2], MODNet [3], PortraitNet [4]의 다양한 Portrait matting 모델을 비교했다. 이 중 가장 최신 모델이면서 높은 정확도를 가진 모델인 MODNet을 기반 모델로 선정했다.

MODNet은 Portrait matting을 위해 제안된 딥러닝 모델로, Semantic estimation, Detail prediction, Semantic-detail fusion의 세 단계로 나누어 Portrait matting을 수행해 배경을 제거한다. 이는 이미지와 영상을 머리카락 한 올까지 세밀하고 정확하게 Portrait matting하지만 실시간으로 사용할 수 있을 만큼 속도가 높지 않다. 반면 자체 제작 모델은 그 정도의 높은 예측 정확도를 요하지 않을 뿐더러, 높은 예측 정확도보다는 빠른 실시간 예측 속도가 중요하다. 이에 기존 MODNet 구조에서 Semantic estimation만을 실행한 후, Dense connection [5] 과 upsampling, convolution layer을 추가한 자체 모델 구조를 제작한다.

자체 모델의 높은 정확도를 위해 전이 학습을 통해 사전 학습한 MODNet의 가중치를 복제한 뒤, 추가한 층과 최상위 층의 일부를 학습 하는 미세 조정 (Fine-tuning)으로 학습한다. 이때 학습데이터는 Knowledge disitillation [6] 을 통해 입력 이미지에 대한 사전 학습한 MODNet 모델의 출력값을 Ground truth로 제작한다. 또한, 학습 시 PortratiNet [4] 에서 제시한 Consistency constraint loss을 추가해 조명 밝기와 카메라 화질과 같이 다양한 사용 환경에서도 안정적으로 모델이 예측할 수 있도록 한다.

본 보고서의 자체 모델은 기존 MODNet과 비교해 다양한 장점을 가진다. 첫째, 자체 모델이 더 빠르다. 2.6GHz 6코어 Intel Core i7 CPU 환경에서 자체 모델의 실행 속도는 11.4 frames per second (*fps*)로, MODNet의 추론 시간인 7.8 frames per second (*fps*)보다 약 1.5배 빠르다. 둘째, 자체 모델이 더 정확하다. MODNet은 특이한 자세나 의상에서 예측이 잘 되지 않는데, 자체 모델에서는 이 문제점이 개선되었다. 셋째, 자체 모델이 더 안정적이다. 자체 모델은 학습 시 Consistency constraint loss을 추가함으로써 다양한 사용 환경에서도 안정적으로 예측할 수 있다. 마지막으로, 자체 모델의 학습이 더 용이하다. RGB 이미지와 이에 해당하는 Trimap, Ground truth을 입력 이미지로 사용하는 MODNet과 달리, 자체 모델은 RGB 이미지만을 입력 이미지로 사용해 학습을 함으로써, 학습을 용이하게 한다.

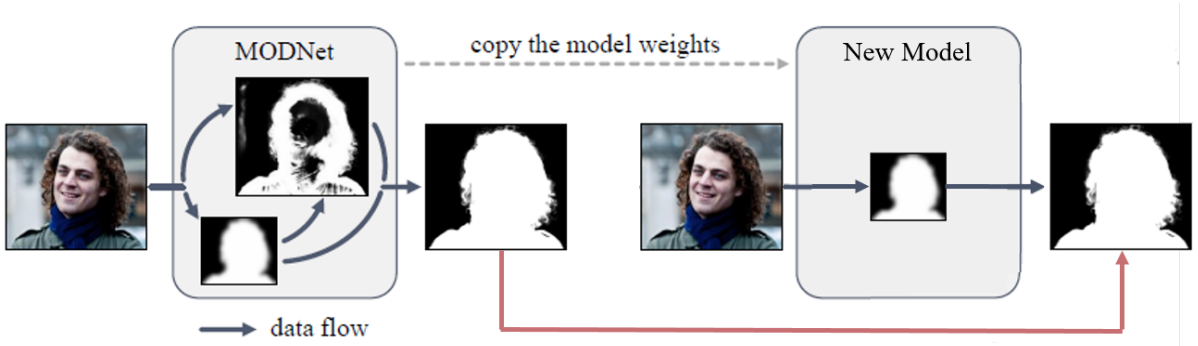

그림 1. **연구 개요.** 본 보고서는 간단하고, 빠르고 효과적인 실시간 Portrait matting 모델을 제시한다. (1) MODNet 모델을 기반으로 더 간단하고 빠른 자체 모델을 제작한다. (2) Knowledge distillation과 전이 학습을 통해 RGB 이미지만을 입력 이미지로 사용해 자체 모델을 학습한다.

(3) 모델의 안정성을 강화하기 위해 Consistency constraint loss을 추가한다.

2 관련 연구

2.1. Image Matting

Image matting의 목적은 주어진 이미지(Image) I에서 전경(Foreground) F을 추출하는 것이다. 이진 마스크를 결과로 출력하는 이미지 분할과 달리, Image matting은 각 픽셀에 대해 정확한 전경 확률로 alpha matte 값을 예측하며, 다음 공식에서 α로 표현된다:

$$I = \alpha^i F^i + (1 - \alpha^i) B^i,$$

위 식에서 i는 pixel index이며, B는 I의 배경(Background)이다.

2.2. 전이 학습 (Transfer learning)

전이 학습은 사전 학습한 모델(Pretrained model)을 사용해 새로운 모델을 만들 시 짧은 시간 내에 높은 정확도를 달성하는 방법이다. 전이 학습을 하는 이유는 다음과 같다: (1) 실질적으로 convolution network을 처음부터 학습시키는 경우는 많지 않으며 대부분의 문제는 사전 학습한 모델을 사용해 해결할 수 있다; (2) 복잡한 문제일수록 학습시키기 어려우며 상당한 시간이 소요된다; (3) 모델의 층의 개수, activation, hyper parameter와 같이 고려해야 할 요소가 많으며, 처음부터 학습시키려면 많은 시도가 필요하다. 결론적으로 이미 잘 훈련된 모델이 있고, 특히 해당 모델과 유사한 문제 해결 시 전이 학습을 사용한다.

전이 학습 시 성능을 더욱 향상시키는 방법은 추가한 층과 함께 사전 학습한 모델의 최상위 층의 가중치를 함께 학습, 즉 미세 조정(Fine tuning)하는 것이다. 대부분의 convolution network는 층이 높을수록 더 전문화된다. 처음 몇 층은 간단하고 일반적인 특징을 학습하고, 높은 층으로 갈수록 구체화된다. 이에 미세 조정은 일반적인 학습을 하는 층은 고정하고, 전문화된 특징이 새로운 데이터셋에 맞춰 동작할 수 있도록 소수의 최상위 층만 학습시킨다. 이는 일반적으로 학습 데이터셋의 규모가 크고, 사전 학습한 모델이 사용한 원래 데이터셋과 유사한 경우에 사용한다.

3 연구 내용

이 장에서는 MODNet의 구조와 이를 바탕으로 제작한 자체 모델에 대한 구조에 대해 소개하고, 모델의 안정성을 강화하기 위한 Consistency constraint loss에 대해 설명한다.

3.1. MODNet

MODNet [3] 은 Portrait matting을 위해 제안된 딥러닝 모델로, 하나의 RGB 이미지를 입력값으로 사용하고, 단일 모델로 실시간 Portrait matting을 수행해 배경을 제거하는 모델이다. Portrait matting은 다른 Image matting에 비해 머리카락과 같이 가장자리의 경계가 분명하지 않아 세밀한 가장자리 예측이 어렵다. 이에 MODNet은 Portrait matting을 세분화해 세 단계로 나누어져 진행한다: (1) Semantic estimation, (2) Detail prediction, (3) Semantic-detail fusion. 우선 Semantic estimation 단계에서 거친 전경 마스크(Coarse foreground mask)을 예측하고, Detail prediction 단계에서 세밀한 전경의 가장자리를 예측한다. 마지막으로 Semantic-detail 단계는 두 하위 목표의 예측값인 Semantic과 Detail을 합쳐 최종 alpha matte 값을 예측한다.

MODNet은 이 세 단계를 각각 학습하는 세 개의 상호의존적 branch인 S, D, F로 구성된다. (그림 1) Semantic estimation 단계를 학습하는 S branch는 실시간 사용을 용이하게 하기 위해 기반 모델로 MobileNetV2 [1] 을 사용한다. MobileNet은 작은 사이즈로 최적화되어 있어 빠른 수행시간을 가져 모바일 기기나 자원이 한정적인 기기에서 동작하기에 이상적인 모델이다. Semantic을 예측하는 과정에서 다른 채널에 비해 정확한 예측값을 갖는 채널이 있으며, 이 채널은 입력 이미지에 따라 달라진다. 이에 Channel-wise attention을 활용한 SE-block [7] 을 추가함으로써 채널에 가중

치를 부여한다. 기존 MobileNet 구조에 SE-block을 추가하면, 미미한 연산량의 증가로 큰 성능 향상을 달성할 수 있다. 손실은 sp와 G(αg)와의 차이를 통해 계산한다. G(αg)는 Ground truth matte인 αg을 16배 downsampling 하고 Gaussian blur한 값으로, Human semantics에 필수적이지 않은 머리카락과 같은 세부 정보를 제거한다. 이때 예측값 sp는 매끄러워야 하므로 L2 손실 함수를 사용한다.

Detail prediction 단계를 학습하는 D branch는 이미지의 가장자리를 세밀하게 예측하는 것이 중요하므로, High-resolution branch을 통해 고해상도 이미지를 유지한다. 이는 입력 이미지를 1/4배 downsampling한 고해상도 이미지와 S branch의 저해상도 이미지를 입력값으로 사용해 details dp을 예측한다. 손실은 예측값 dp와 Ground truth matte인 αg와의 차이를 가장자리 부분에 대해서만 L1 손실 함수를 사용해 계산한다.

Semantic-detail fusion 단계를 학습하는 F branch는 S branch의 예측값 sp와 D branch의 예측값 dp을 먼저 upsampling을 통해 차원(shape)을 맞춘 후, 이를 합쳐 최종 alpha mate인 αp을 예측한다. 손실은 예측값 αp와 Ground truth matte인 αg와의 차이를 L1 손실 함수를 사용해 계산한다.

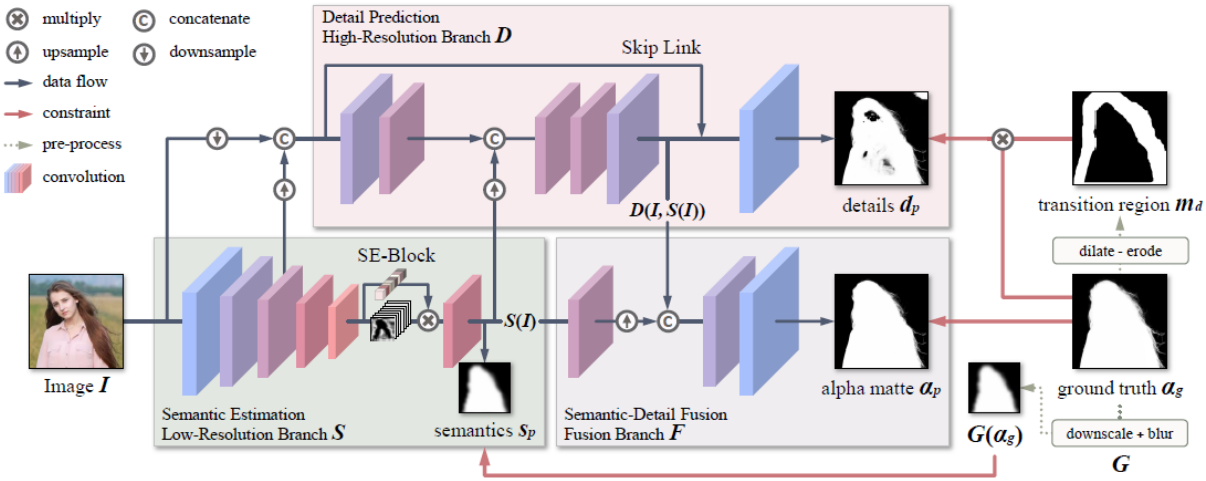

그림 2. **MODNet의 구조.** 입력 이미지 I가 주어지면, MODNet은 human semantics sp, boundary details dp와 최종 alpha matte 값을 세 개의 상호의존적 branch인 S, D, F을 통해 예측한다.

3.2. 자체 모델 구조

이미지와 영상을 머리카락 한 올까지 세밀하고 정확하게 Portrait matting하는 MODNet과 달리, 자체 제작 모델의 경우 그 정도 수준의 높은 예측 정확도를 요하지 않을뿐더러, 높은 예측 정확도보다는 빠른 실시간 예측 속도, 즉 높은 fps가 중요하다. 이에 기존 MODNet 구조에서 Detail prediction을 하지 않고, Semantic estimation을 실행하는 S block에 upsampling과 convolution layer을 추가해 자체 모델 구조를 제작한다. 이는 기존 MODNet의 S block의 예측값 sp의 차원을 최종 alpha matte와 맞추기 위해 bilinear interpolation을 이용한 upsampling 후 convolution을 해, 해상도 증가와 동시에 학습할 수 있는 구조이다.

Semantics만 학습하면 되는 기존 S block과 달리 Detail도 함께 학습해야 하므로, 손실은 예측값 αp와 Ground truth matte인 αg와의 차이를 L1 손실 함수를 사용해 계산한다:

$$L = ||\alpha p - \alpha g||_1.$$

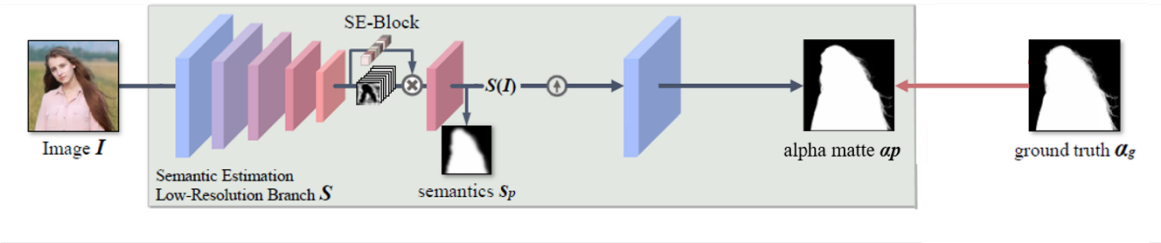

그림 3. **자체 모델 구조.** 기존 MODNet의 S block에 bilinear interpolation을 이용한 upsampling과 convolution layer을 추가한다.

다만 위 모델의 경우 S block의 예측값 sp의 해상도는 입력 이미지의 1/16에 불과하며, 이미지의 세부 정보가 많이 삭제되어 bilinear interpolation을 통해 원래 이미지의 크기로 복원 후 convolution을 통해 학습을 해도 최종 alpha matte의 성능이 높지 않다. 이러한 문제점을 보완하기 위해, 이미지의 세부 정보를 포함하는 고해상도 이미지를 사용하고자 Dense connection [5] 을 추가한다. 이때 Residual connection [8] 이 아닌 Dense connection을 사용한 이유는, 학습 데이터셋이 충분하지 않아 Dense connection의 regularizing 효과를 통해 과적합 (overfitting)을 줄이기 위해서이다.

본 모델에서는 기존 MODNet의 S block의 예측값 sp을 4배 upsampling한 이미지와 Dense connection을 통해 입력 이미지를 1/4배 downsampling한 고해상도 이미지, 기반 모델의 저해상도 이미지를 입력값으로 사용해 alpha matte을 예측한다. 이때 기반 모델의 저해상도 이미지를 입력값으로 재사용하는 이유는 computational overhead을 줄이기 위해서이다. 이후 bilinear interpolation을 이용한 upsampling 후 convolution을 해 최종 alpha matte αp을 예측한다.

손실은 예측값 αp와 Ground truth matte인 αg와의 차이를 L1 손실 함수를 사용해 계산한다:

$$L = ||\alpha p - \alpha g||_1.$$

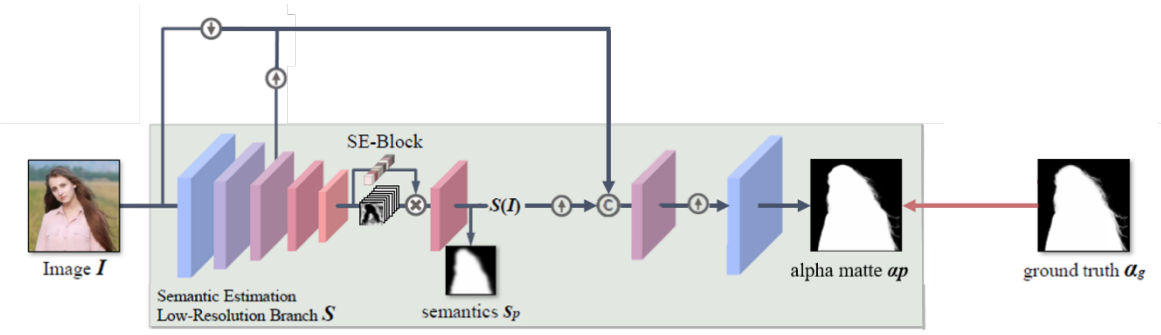

그림 4. **Dense Connection을 추가한 자체 모델 구조.** 이미지의 세부 정보를 잃지 않기 위해 고해상도 이미지를 사용하고자 Dense connection을 추가한다.

3.3. Consistency Constraint Loss

조명 밝기와 카메라 화질과 같이 다양한 사용 환경에서도 안정적으로 모델이 예측할 수 있도록 PortratiNet [4] 에서 제시한 Consistency constraint loss을 추가한다. 우선 원본 이미지 A에 대해 랜덤으로 질감 변형 (Texture augmentation)을 해 A'을 생성한다. 질감 변형은 이미지의 밝기와 대비와 같은 질감을 변형시키는 것으로, 이미지의 형태에 변화를 주지 않으므로 A와 A'에 대한 모델의 alpha matte 예측값인 B와 B'은 같아야 한다. 하지만 질감 변형을 하게 되면 이미지의 품질이 낮아지게 되어 A'의 예측값인 B'은 A에 대한 예측값인 B보다 성능이 낮다. 이에 B와 B'의 Consistency constraint loss을 L1 손실 함수를 사용해 계산해 더해줌으로써 Consistency을 유지할 수 있도록 한다. Consistency constraint loss는 다음과 같이 계산한다:

$$L'm = F.l1_loss(p'i,\ yi)$$
$$Lc = F.l1_loss(p'i,\ pi)$$
$$loss = L'm + \alpha \times Lc,$$

위 식에서 yi는 입력 이미지에 대한 Ground truth 값이고, $p'i$와 pi는 각각 A'와 A에 대한 모델의 alpha matte 예측값이다. Consistency constraint loss는 모델의 정확도를 향상시키며, 다양한 조명 상태에서도 모델이 안정적으로 작동할 수 있게 한다.

4 연구 결과

이 장에서는 먼저 데이터셋과 학습 방법에 대해 소개하고, PPM-100에 대한 결과와 실제 적용 결과에 대해 MODNet 모델과 자체 제작 모델을 비교한다.

4.1. 학습 데이터

학습 데이터를 얻기 쉽고 쉽게 제작할 수 있는 이미지 인식과 객체 탐지와 달리, Image matting은 양질의 데이터를 얻기 쉽지 않으며 제작하는 데에도 긴 시간과 노력이 소요된다. 이에 학습 데이터를 얻기 위해 Knowledge distillation [8] 을 통해 입력 이미지에 대한 사전 학습한 MODNet 모델의 출력값을 Ground truth로 새로 만든 자체 제작 모델을 학습한다.
입력 이미지는 2,667개의 인물 이미지로 구성되는 Supervisely Person Segmentation (SPS) [9] 데이터셋을 사용한다. SPS는 다양한 신체 부위와 복잡한 배경을 포함한 인물 이미지를 가진다. 일부 이미지는 그림 5 에서 볼 수 있다.

그림 5. **SPS.** 학습 데이터셋으로 사용한 SPS 데이터셋

4.2. 데이터 증강 (Data augmentation)

학습한 모델의 안정성을 강화하기 위해, 이미지의 질감 변형을 통해 데이터 증강을 한다. 본 실험의 질감 변형은 다음을 포함한다:

- 랜덤 노이즈 {가우시안 노이즈, σ=10}
- 이미지 블러 {커널 크기는 3 과 5 중 무작위 선정}
- 랜덤 색상 변형 {0.4 ~ 1.7}
- 랜덤 밝기 변형 {0.4 ~ 1.7}
- 랜덤 대비 변형 {0.6 ~ 1.5}
- 랜덤 선명도 변형 {0.8 ~ 1.3}

위의 모든 질감 변형은 각각 0.5의 확률로 무작위로 이루어졌으며. 그림 6 에서 질감 변형된 학습 데이터를 볼 수 있다.

그림 6. **이미지 질감 변형을 통한 데이터 증강.** (a)는 원본 이미지, (b)는 0.5의 확률로 무작위로 질감 변형이 이루어진 이미지, (c)는 Ground truth이다.

4.3. 학습 방법

자체 제작 모델의 높은 정확도를 위해 전이 학습을 통해 사전 학습한 MODNet의 가중치를 복제한 뒤, 추가한 층과 최상위 층의 일부를 학습하는 미세 조정 (Fine-tuning)으로 학습한다. 이때 검증 데이터에 대한 검증 손실값을 비교해 훈련 가능한 최상위 층을 선택한다. 학습률은 0.0001로 40 epcoch 훈련한다.

학습이 끝난 뒤, 모델의 안정성을 강화하기 위한 Consistency constraint loss 추가를 위해 각 학습 데이터에 대해 10배의 질감 변형을 한 이미지를 추가 학습한다. 학습률은 0.00001로 10 epoch으로 모든 층에 대해 학습한다.

4.4. PPM-100에 대한 결과

검증 데이터는 Photographic Portrait Matting benchmark (PPM-100) [1] 을 사용한다. PPM-100은 그림 6의 (a)(b)(c)와 같이 다양한 인물 이미지와 이에 해당하는 Portrait Matting 100개로 구성된다.

그림 7. **PPM-100**. 검증 데이터로 사용한 PPM-100 데이터셋은 (a) 세밀한 머리카락, (b) 추가적인 물건, (c) 다양한 신체 부위를 포함한 다양한 인물 이미지를 가진다.

모델의 정확성을 비교하기 위한 정량적 지표로 Mean Square Error (MSE)와 Mean Absolute

Difference (MAD)를 사용한다. 표 1 은 PPM-100에 대한 MODNet 모델과 자체 제작 모델에 대한 MSE와 MAD을 보여준다. MODNet-S는 MODNet의 S block에 upsampling과 convolution을 추가한 모델로 (그림 3) MODNet에 비해 정확도가 떨어진다. 하지만 MODNet-D은 MODNet-S에 Dense connection을 추가한 모델로 (그림 4), MODNet보다 모델의 예측 정확도가 높다. MODNet-C는 MODNet-D에 Consistency constraint loss을 추가한 모델로, Consistency constraint loss을 추가하면 모델의 예측 정확도가 높아지는 것을 볼 수 있다. MODNet과 MODNet-C을 비교하면 자체 제작 모델의 정확도가 현저히 높은 것을 확인할 수 있다. 그림 8 에서 일부 이미지에 대한 결과를 볼 수 있다.

	Consistency Constraint Loss	MSE↓	MAD↓
MODNet		0.01324	0.01944
MODNet-S		0.01700	0.02445
MODNet-D		0.01098	0.01679
MODNet-C	✓	**0.00829**	**0.01362**

표 1. **PPM-100에 대한 정량적 결과.** ↓은 낮을수록 좋은 모델이라는 뜻이다.

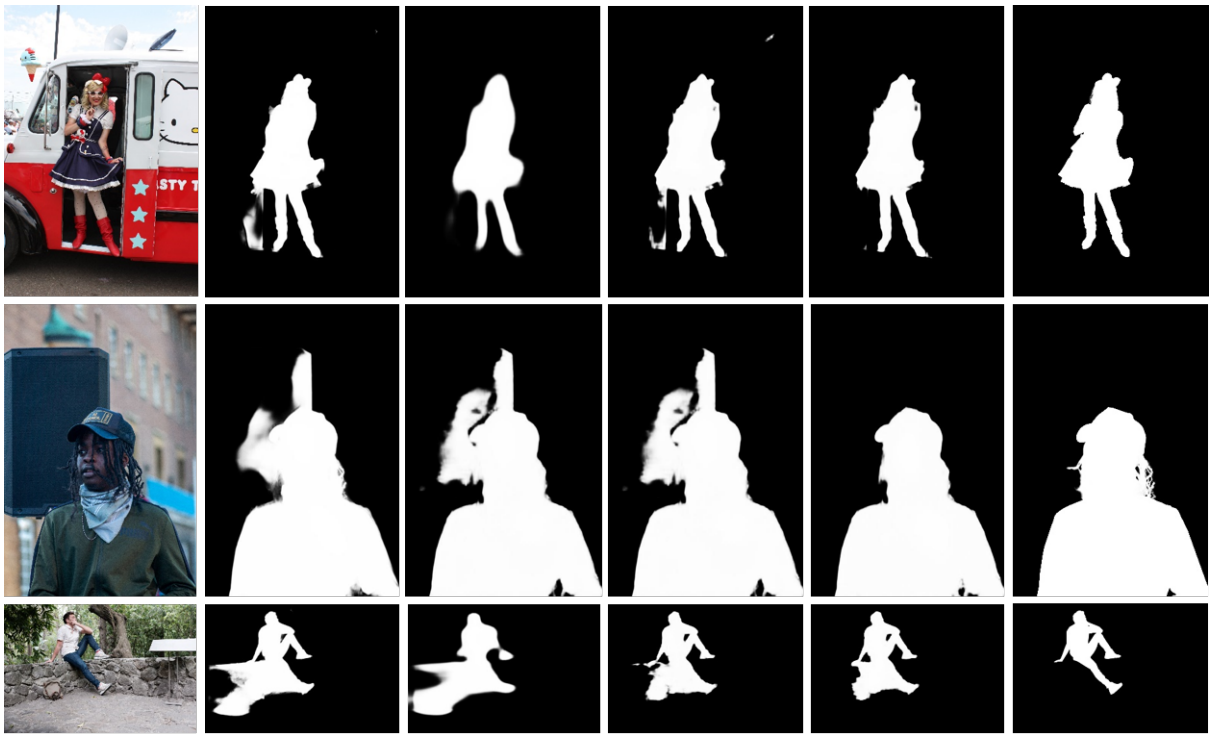

입력 이미지 MODNet MODNet-S MODNet-D MODNet-C GT

그림 8. **PPM-100에 대한 시각적 비교.** 자체 제작 모델이 특이한 자세나 의상 (첫 번째 행) 과 배경과 전경의 색상이 비슷한 경우 (두 번째 행) 더 잘 예측한다. 하지만, 여전히 일부 특이한 자세에 대해서는 예측이 잘못된 경우가 드물게 있다 (세 번째 행).

4.4. 실제 적용 결과

자체 제작 모델은 모델 크기와 실행 속도에서도 뛰어나다. 모델 크기는 총 파라미터의 수로 비교하며, 실행 속도는 2.6GHz 6코어 Intel Core i7 CPU 환경에서 추론 시간 (Inference time)을 측정한다. 그림 9 는 이 두 가지 지표로 비교한 결과를 보여준다. MODNet-C의 추론 시간은 87.7*ms* (11.4 *fps*)로, MODNet의 추론 시간인 128.2*ms* (7.8 *fps*)보다 약 1.5배 빠르다. 또한, MODNet-S와 MODNet-C을 비교하면 Dense connection을 추가함으로써 정확도는 크게 증가하지만 (표 1), 추론 시간 및 총 파라미터 수에 영향은 미미한 것을 볼 수 있다. 이때 MODNet-D와 MODNet-C의 차

이는 Consistency constraint loss을 추가해준 것으로 구조는 같으므로 추론 시간과 총 파라미터 수에는 변함이 없다.

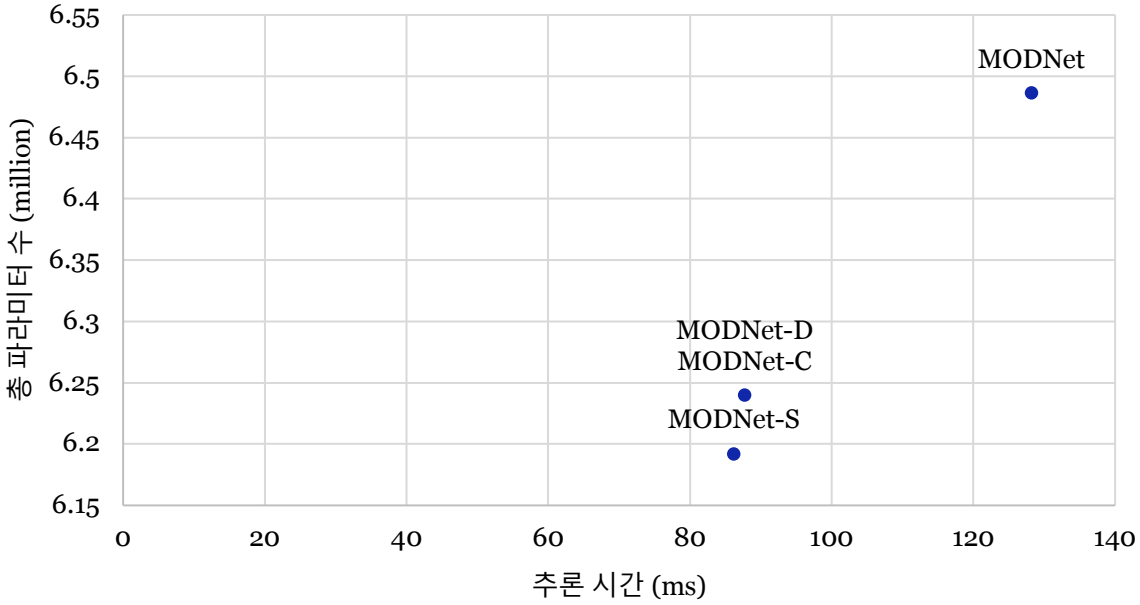

그림 9. **모델 크기와 실행 속도 비교.** 추론 시간이 짧을수록 좋고, 모델 파라미터 수가 적을수록 좋은 모델이다. 1000을 추론 시간으로 나누면 이미지가 보여지는 속도인 *fps*, frames per second을 구할 수 있다.

5 결론

본 보고서는 간단하고, 빠르고 효과적인 실시간 Portrait matting 모델을 제시한다. Labeled된 학습 데이터 없이 RGB 이미지만을 입력 이미지로 사용해 학습을 함으로써, 학습을 용이하게 한다. 또한 Consistency constraint loss을 통해 다양한 사용 환경에서 모델의 안정성을 강화하고 정확도를 향상한다. 이에 기존 모델인 MODNet의 한계점 중 하나인 특이한 자세나 의상에서 예측이 잘 되지 않는다는 문제점을 개선했으며 (그림 8), 정량적으로 비교해도 MODNet에 비해 높은 정확도를 가지면서도 높은 속도와 낮은 총 파라미터 수를 가진다.

MODNet의 또 다른 문제점인 배경과 전경의 색상이 비슷한 경우에 예측이 잘 되지 않는다는 한계점도 다소 개선했다. 하지만 본 모델을 실시간으로 사용할 시에 위 문제점이 두드러지는 경우가 있다. 이는 추출된 전경에 대해서 배경 대체를 통한 데이터 증폭된 이미지를 이용해 학습하면 위 문제점이 개선될 것으로 예상된다. 하지만 학습 데이터인 SPS을 배경 대체를 통해 각각 10배씩 데이터 증폭해 학습하면 모델의 정확도가 낮아진다. 이는 그림 10 에서 볼 수 있듯이, 합성된 이미지에서 전경과 배경의 가장자리에 존재하는 미세한 차이를 모델이 학습하는 것이 원인이다. 따라서 배경 대체를 통한 데이터 증폭을 위해서는 Image matting이 높은 수준으로 이루어진 데이터셋이 요구된다.

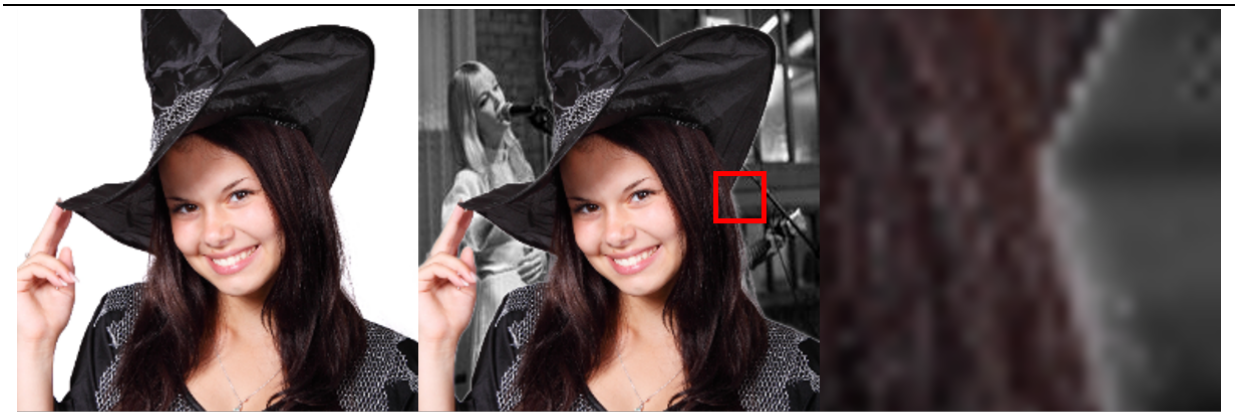

(a) (b) (c)

그림 10. (a) 원본 이미지와 (b) 추출된 전경과 배경을 합성한 이미지이다. (c) 가장자리 부분을 확대해 보면 미세하게 전경과 배경 사이에 하얀색 테두리가 존재하는 것을 볼 수 있다.

References

[1] Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). Mobilenetv2: Inverted residuals and linear bottlenecks. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 4510-4520).

[2] Chen, L. C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. In Proceedings of the European conference on computer vision (ECCV) (pp. 801-818).

[3] Ke, Z., Li, K., Zhou, Y., Wu, Q., Mao, X., Yan, Q., & Lau, R. W. (2020). Is a Green Screen Really Necessary for Real-Time Portrait Matting?. *arXiv preprint arXiv:2011.11961*.

[4] Zhang, S. H., Dong, X., Li, H., Li, R., & Yang, Y. L. (2019). PortraitNet: Real-time portrait segmentation network for mobile device. Computers & Graphics, 80, 104-113.

[5] Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 4700-4708).

[6] Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*.

[7] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 7132-7141).

[8] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).

[9] supervise.ly. Supervisely person dataset. supervise.ly, 2018.